

Аналитическая модель вычислительной стоимости CNN
Исследуется один прямой проход заданной сети для датасета B изображений

Вход $[B, 3, S, S]$, где S равно 16. Выход имеет форму $[B, 100]$

Используются FP32, eval() и inference_mode().

Одно значение FP32 занимает 4 байта.

После каждой свёртки выполняется ReLU(inplace = True).

После первой свёртки и ReLU следует Max Pool.

BatchNorm отсутствует. Между двумя Linear также используется ReLU(inplace = True).

Обозначения

$C; C_0$ - число входных и выходных каналов

H_i, W_i, H_o, W_o - пространственные размеры входа и выхода

k, s, p - размер ядра, шаг и padding.

P_L - число параметров слоя

F_L - число арифметических FLOPs.

P_L - оценка трафика слоя в байтах.

Соглашения

- 1) Свёртки обычные, без групп, $dilation = 1$, $p = \lfloor k/2 \rfloor$, $bias = False$
Неуказанный шаг принимается = 1.
- 2) Для обоих Linear $bias = True$, это допущение т.е. условие не задаёт bias линейных слоёв
- 3) $1 MAC = 2 FLOPs$. Сравнения учитываются отдельно
- 4) Для памяти считаем сумму параметров и активаций.
Включаем исходный вход. Общее хранилище inplace-ReLU и Flatten повторно не учитываем.

Размеры тензоров, параметры и FLOPs.

Размер выхода свёртки

$$H_0 = \left\lfloor \frac{H_i + 2p - k}{s} \right\rfloor + 1, W_0 = \left\lfloor \frac{W_i + 2p - k}{s} \right\rfloor + 1$$

Формула считает допустимые положения окна с шагом s на дополненном входе. Для MaxPool используем аналогичный расчёт с округлением вниз.

Для свёртки:

$$P_{conv} = C_0 C_i k^2,$$

$$F_{conv} = 2 B H_0 W_0 C_0 C_i k^2.$$

Каждый выходной элемент требует $C_i k^2$ MAC. Учитываем полное окно, включая позиции padding.

Для Linear с n входами, m выходами и bias:

$$P_{linear} = nm + m,$$

$$F_{linear} = Bm(2n + 1)$$

Здесь учитываются и MAC и одно добавление bias на выходной элемент.

Для первой свёртки:

$$H_0 = W_0 = \left\lfloor \frac{S+6-7}{2} \right\rfloor + 1 = \frac{S}{2},$$

$$P_1 = 32 \cdot 3 \cdot 7^2 = 4704,$$

$$F_1 = 2B \left(\frac{S}{2}\right)^2 \cdot 32 \cdot 3 \cdot 7^2 = 2352 B S^2.$$

Формы данных батча:

Операция	Форма выхода на умножение	Параметры	Арифметические FLOPs
Conv1 7x7, S2, 3 → 32 + ReLU	32 x S/2 x S/2	4704	2352 B S ²
MaxPool 3x3, S2, P1	32 x S/4 x S/4	0	0

Conv2 5×5 , $32 \rightarrow 64 + \text{ReLU}$	$64 \times S/4 \times S/4$	51 200	$6400BS^2$
Conv3 3×3 , S2, $64 \rightarrow 128 + \text{ReLU}$	$128 \times S/8 \times S/8$	73 728	$2304BS^2$
Conv4 1×1 $128 \rightarrow 256 + \text{ReLU}$	$256 \times S/8 \times S/8$	32 768	$1024BS^2$
Conv5 3×3 , S2, $256 \rightarrow 256 + \text{ReLU}$	$256 \times S/16 \times S/16$	589 824	$4608BS^2$
Conv6 1×1 , $256 \rightarrow 512 + \text{ReLU}$	$512 \times S/16 \times S/16$	131 072	$1024BS^2$
Global Avg Pool	$512 \times 1 \times 1$	0	$2BS^2$
Flatten	512	0	0
Linear $512 \rightarrow 256$	256	131 328	$262400B$
ReLU inplace	256	0	0
Linear $256 \rightarrow 100$	100	25 700	$51300B$

ReLU и MaxPool не добавляют арифметических FLOPs по принятому соглашению. Их сравнения посчитаны ниже. В GlobalAvgPool усредняется $N = (S/16)^2$ чисел на канал. Это $N-1$ сложений и одно деление. Считая каждое за одну FLOP:

$$F_{\text{GAP}} = 512B[(N-1)+1] = 2BS^2$$

Сумма параметров:

$$P_{\text{total}} = 883256 + 131328 + 25700 = \boxed{1040324}$$

Сумма FLOPs:

$$F(S, B) = (2352 + 6400 + 2304 + 1024 + 4608 + 1024 + 2) \cdot BS^2 + (262400 + 51300)B.$$

$$FLOPs(S, B) = 17714BS^2 + 313700B$$

Для MaxPool принимаем восемь сравнений на полное окно 3×3 :

$$N_{\text{cmp, pool}} = 8B \cdot 32 \left(\frac{S}{4} \right)^2 = 16BS^2$$

Для шести ReLU после свёрток и ReLU в голове:

$$N_{\text{cmp, ReLU}} = (8 + 4 + 2 + 4 + 1 + 2)BS^2 = 256B.$$

Итого: $N_{\text{cmp}}(S, B) = 37BS^2 + 256B$

Память

Используем модель суммы:

$\hat{M}(S, B) = 4(P_{\text{total}} + A_{\text{total}})$, где A_{total} - суммарное число элементов входа и активаций без повторного счёта общего хранилища.

Количество пространственных элементов:

Тензор	Число элементов
Вход	$3BS^2$
Выход Conv1/ReLU	$8BS^2$
Выход MaxPool	$2BS^2$
Выход Conv2/ReLU	$4BS^2$
Выход Conv3/ReLU	$2BS^2$
Выход Conv4/ReLU	$4BS^2$
Выход Conv5/ReLU	BS^2
Выход Conv6/ReLU	$2BS^2$

$$\Rightarrow A_{\text{spatial}} = 26BS^2.$$

Для головы:

$$A_{head} = 512B + 256B + 100B = 868B$$

Flatten и inplace-ReLU не создают отдельных хранилищ элементов.

$$\hat{M}(S, B) = 4(1040324 + 26BS^2 + 868B)$$

$$Memory(S, B) = 4161296 + 104BS^2 + 3472B \text{ байт}$$

Временные рабочие буферы не учитываются. Это аналитическая модель суммы, которую сравниваем с измеренным пиком `torch.cuda.max_memory_allocated()`. Освобождение активаций и временные буферы могут приводить к расхождениям.

Объём перемещаемых данных

Допущение: вход и параметры каждой операции считываются один раз, выход записывается один раз. Повторные чтения, кеширование между операциями и трафик временных буферов не учитываются. Параметры считываются один раз на весь дат.

Для conv и Linear:

$$D_e = 4(N_{in,e} + P_e + N_{out,e})$$

Для pooling параметров нет. ^{Для} ~~Над~~ ReLU над N элементами:

$$D_{ReLU} = 4N + 4N = 8N$$

Inplace не обменивает чтение и запись. Для Flatten принимаем $D=0$.

Трафик операций без шести ReLU после свёрток:

Операция	Трафик, байт
Conv1	$44BS^2 + 18816$
MaxPool	$40BS^2$
Conv2	$24BS^2 + 204800$
Conv3	$24BS^2 + 294912$

Conv 4	$24BS^2 + 131072$
Conv 5	$20BS^2 + 2\ 359\ 296$
Conv 6	$12BS^2 + 524\ 288$
Global Avg Pool	$8BS^2 + 2048B$
Linear 1	$3072B + 525\ 312$
ReLU в голове	$2048B$
Linear 2	$14\ 24B + 102\ 800$

Пример для conv 1

$$D_{\text{conv1}} = 4(3BS^2 + 41704 + 8BS^2) = 44BS^2 + 18816$$

Трафик ReLU после Conv1 - Conv6 соответственно:

$$(D_{R1}, D_{R2}, D_{R3}, D_{R4}, D_{R5}, D_{R6}) = BS^2(64, 32, 16, 32, 8, 16).$$

$$D_{\text{ReLU, conv}} = 168BS^2$$

Суммируя все операции:

$$D(S, B) = (196 + 168)BS^2 + 8592B + 4161\ 296.$$

$$D(S, B) = 364BS^2 + 8592B + 4161\ 296 \text{ байт}$$

Latency

Допущения: операции сети выполняются последовательно, внутри операции вычисления и передачи данных прерываются, эффективные скорости считаются общими для всех операций, постоянные накладные расходы прохода представлены параметром t_0 .

Параметры модели:

$$\Theta = (t_0, P_{\text{eff}}, BW_{\text{eff}}), \text{ где } t_0 \geq 0 \text{ накладные расходы сек, } P_{\text{eff}} > 0 \text{ эффективная производительность, FLOPs,}$$

$BW_{eff} > 0$ эффективная пропускная способность, байт/с
Время вычислений и передачи данных операции:

$$T_{compute, l} = \frac{F_e}{P_{eff}}, \quad T_{memory, l} = \frac{D_e}{BW_{eff}}$$

Итоговая функция:

$$Latency(S, B, \Theta) = t_0 + \sum_l \max \left(\frac{F_e(S, B)}{P_{eff}}, \frac{D_e(S, B)}{BW_{eff}} \right).$$

Выражения F_e, D_e заданы выше. В сумме иногда свёртка и следующая за ней ReLU учитываются отдельными операциями, Flatten отдельного вклада не оказывает.

Для ReLU и MaxPool используется приближение времени по трафику, отдельное время сравнений не моделируется.

Результат измеряется в секундах на один forward батча. Коэффициенты подбираются по калибровочным измерениям медианного времени.

Интерпретация режимов:

- преобладает t_0 - launch-bound
- для операций больше D_e/BW_{eff} - memory-bound
- больше F_e/P_{eff} - compute-bound.

Energy

Энергия всего GPU за проход:

$$E = \int_0^T P_{GPU}(t) dt.$$

Допущение: средняя мощность всего GPU приблизительно постоянна для исследуемых конфигураций. Мощность простое не вычитается.

Тогда:

$$\text{Energy}(S, B, \Theta_E) = \bar{P}_{GRU} \text{Latency}(S, B, \Theta)$$

$$\Theta_E = (\Theta, \bar{P}_{GRU})$$

Здесь $\bar{P}_{GRU} \geq 0$ измеряется в ваттах, результат в джоулях.

$$B_i \cdot c = \text{Дж}.$$

Сначала калибруются параметры времени, затем коэффициент средней мощности по измерениям энергии. Уменьшение мощности с нагрузкой - ограничение модели.

Параметры подбираются только на калибровочной части данных. Прогнозы времени и энергии проверяются на отложенных конфигурациях (S, B) .