Разбор статьи “Deep Learning on a Data Diet: Finding Important Examples Early in Training”

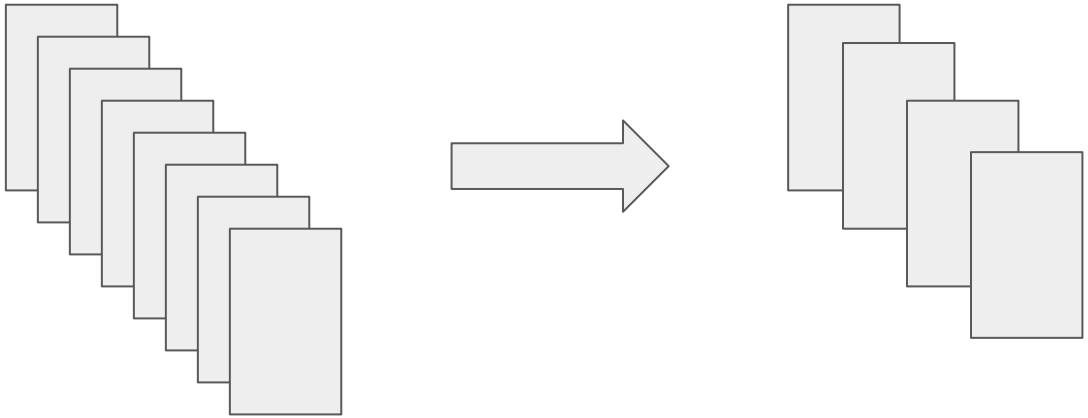
Статья: Mansheej Paul, Surya Ganguli, Gintare Karolina Dziugaite NeurIPS 2021 (версия 2023)

Выполнила: Решетняк А.А.

ИТМО 2026

Центральный вопрос

Авторы исследуют, можно ли оставить только часть обучающих данных и при этом сохранить точность модели. Основной вопрос - как заранее определить, какие примеры стоит оставить



Проблема: все ли обучающие примеры одинаково полезны

Большие датасеты требуют вычислительных ресурсов
Примеры по-разному влияют на обучение
Цель - сократить данные, сохранив точность на тесте

Случайно удалить часть изображений легко, но это может снизить качество. Авторы предлагают оценивать примеры и выбирать подвыборку осмысленно. При этом полезность определяется не красотой или качеством картинки, а ее ролью в обучении

Схема метода

Короткое начальное обучение -> оценки примеров -> отбор подвыборки -> новая модель с нуля -> проверка точности

Удалить примеры с низкими оценками
Оценки усреднены по нескольким независимым обучениям
Тестовые данные в отборе не участвуют

Изначально сеть немного обучают на полном обучающем наборе. После каждому примеру присваивают оценку
После отбора обучают новую модель с другой случайной инициализацией. Именно ее итоговую точность сравнивают с базовыми вариантами

GraNd. Насколько сильный сигнал дает пример

GraNd - средняя по независимым обучениям L2-норма градиента ошибки отдельного примера по параметрам модели

1) Градиент показывает, как ошибка примера меняется при изменении весов
2) Его норма характеризует величину этого сигнала
3) Оценка усредняется по независимым обучениям

Для каждого изображения можно вычислить собственный градиент ошибки по параметрам сети. Большая норма означает сильный сигнал для изменения весов. Это оценка потенциального влияния, и не гарантия полезности - большой градиент может быть и у ошибочно размеченного примера

EL2N. Оценка через ошибку предсказания

EL2N - L2-расстояние между предсказанными вероятностями и правильным ответом

$$EL2N = \|p - y\|_2$$

p - предсказанные вероятности классов

y - правильный ответ в формате one-hot

Правильный ответ y	**Предсказание p**	**EL2N**
[1; 0; 0]	[0,8; 0,1; 0,1]	~ 0,245
[1; 0; 0]	[0,2; 0,7; 0,1]	~ 1,068

Чем сильнее предсказание отличается от правильного ответа, тем выше оценка

В таблице показаны оценки одной модели. В статье их усредняют по нескольким независимо обученным моделям

В отличие от GraNd, EL2N не требует вычисления градиентов по параметрам модели

Постановка экспериментов авторами

Компонент	**Постановка в статье**
Данные	CIFAR-10, CIFAR-100, CINIC-10
Модели	ResNet18, ResNet50
Базовые сравнения	Все данные и случайная подвыборка
Методы отбора	GraNd, EL2N, Forget Score
Повторы	10 для оценок, 4 для итоговой точности

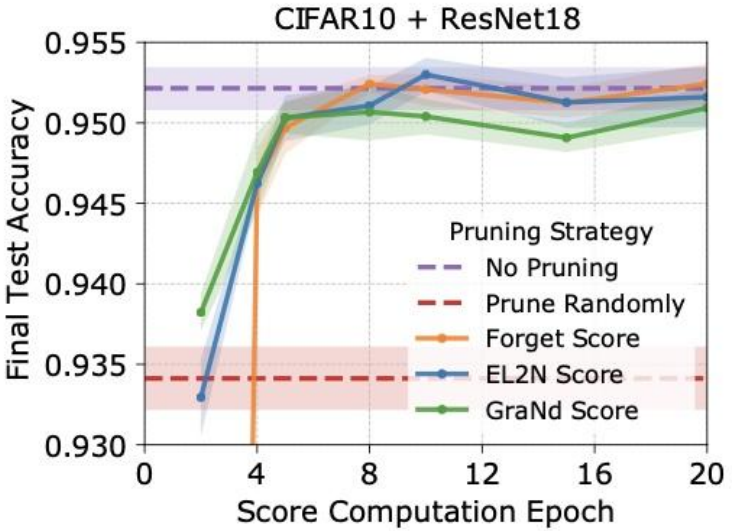
При разных размерах подвыборки число шагов обучения одинаковое. Forget Score учитывает события забывания: модель раньше классифицировала пример правильно, а при следующем наблюдении ошиблась. Его сравнивают с GraNd и EL2N. Чтобы разные методы получили одинаковый бюджет обучения, авторы фиксируют число шагов и расписание скорости обучения

Когда можно отбирать данные

Оценки после короткого обучения уже позволяют находить полезные примеры

CIFAR-10 + ResNet18
Во всех подвыборках оставлено **50% данных**
Меняется момент вычисления оценок

X - эпоха начального обучения, на которой вычислили оценки
Y - итоговая точность **новой модели**, обученной на выбранной половине данных



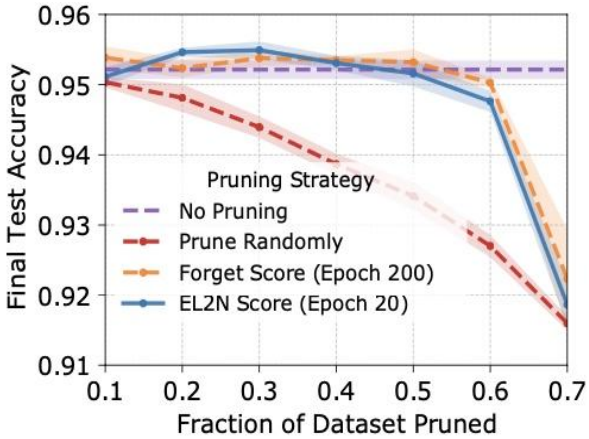
Каждая точка показывает результат отдельного эксперимента с отбором. Через несколько эпох оценки позволяют выбрать половину данных, на которой новая модель достигает точности, близкой к обучению на всем наборе

Источник: Paul et al., Data Diet, arXiv v2 (2023), Fig. 1, стр. 5

Сколько данных можно удалить сохранив качество?

На CIFAR-10 авторы сохранили точность при удалении примерно половины данных
EL2N лучше случайного удаления на значительной части диапазона
Чрезмерное сокращении роняет точность

X - доля удаленных данных
Y - итоговая точность на тесте
EL2N вычислен после 20 эпох начального обучения



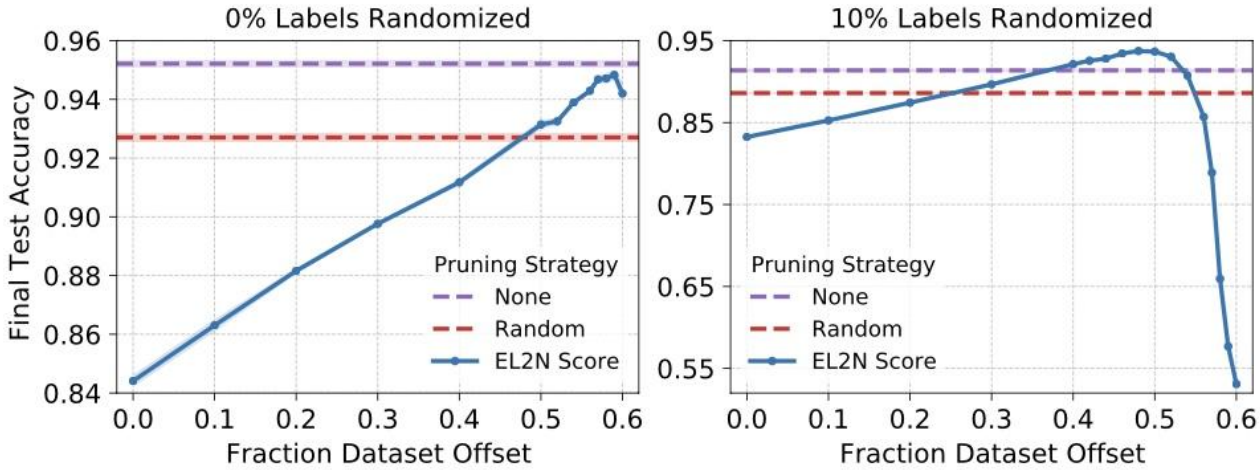
Размер подвыборки изменен. Значение 0,5 на горизонтальной оси означает, что удалена половина обучающих изображений. При осмысленном отборе качество сохраняется дольше, чем при случайном. Удалить почти все без последствий не возможно

Источник: Paul et al., Data Diet, arXiv v2 (2023), Fig. 1, стр. 5

Самая высокая оценка - не всегда означает максимум пользы

Высокая оценка может указывать на сложный пример или ошибку разметки
Отбор только самых высоких оценок не всегда оптимален
При шумных метках исключение крайних примеров может улучшить точность

X - положение начала окна в отсортированном наборе
Y - итоговая точность
Слева -> исходные метки.
Справа -> 10% меток рандомизированы



Размер подвыборки постоянный = 40%. Двигая окно вправо, авторы выбирают все более сложные примеры. В крайней правой точке остаются 40% с самыми высокими оценками. При шумных метках это приводит к падению качества. Сложные примеры могут оказаться ошибочно размеченными

Источник: Paul et al., Data Diet, arXiv v2 (2023), Fig. 2, стр. 6

Выводы статьи

1) Полезную подвыборку можно находить уже на ранних этапах обучения
2) EL2N дает простой способ оценить примеры без градиентов по всем параметрам
3) Результат зависит от степени сокращения и качества разметки

Меньше данных автоматически не гарантирует меньше вычислений

Главный результат - возможность осмысленного отбора данных с сохранением качества в исследованных условиях. Для отбора тоже нужны вычисления. Кроме того, в основных сравнениях авторы сохраняют одинаковое число шагов обучения, поэтому сами эти графики не доказывают ускорение