Отчет о частичном воспроизведении “Deep Learning on a Data Diet: Finding Important Examples Early in Training”

1. Цель работы

Проверить, позволяет ли отбор по EL2N сохранить больше точности при сокращении обучающей выборки CIFAR-10 вдвое, чем случайный отбор.

Постановка основана на статье *Deep Learning on a Data Diet: Finding Important Examples Early in Training*. Воспроизводится часть сравнения из Figure 1: обучение на всех данных, случайной половине и половине, выбранной по EL2N.

2. Постановка эксперимента

Использован CIFAR-10: 50 000 обучающих и 10 000 тестовых изображений размером 32 × 32, 10 классов. Тестовая выборка не участвовала в отборе данных и настройке эксперимента.

Модель - небольшая CNN с 288 746 обучаемыми параметрами.

Три блока содержат по две свертки 3 × 3 с BatchNorm и ReLU, затем MaxPool. Число каналов блоков - 32, 64 и 128. После блоков применяются GlobalAvgPool и Linear на 10 классов. Предобученные веса не используются.

При обучении применяются случайный crop 32 × 32 после padding=4, горизонтальное отражение и нормализация. При вычислении EL2N и тестировании используется только нормализация.

В каждом из 3х независимых повторов:

1. Начальная CNN обучается 5 эпох на полном обучающем наборе.
2. Для каждого обучающего изображения вычисляется $EL2N = \|p - y\|_2$, где p - вероятности классов, y - правильный ответ в one-hot форме.
3. Выбираются 25 000 изображений с наибольшим EL2N и отдельно случайные 25 000 изображений без повторений. Принудительное выравнивание классов не применяется.
4. Три новые модели обучаются с нуля: Full - на всех данных, Random - на случайной половине, EL2N - на отобранной половине.
5. Измеряется точность на общей тестовой выборке.

Настройка	**Значение**
Оптимизатор	SGD, Nesterov momentum = 0,9
Начальный learning rate	0,05
Weight decay	0,0005
Batch size	128
Начальная модель	5 эпох, постоянный learning rate
Каждая итоговая модель	8 000 шагов, cosine-снижение learning rate до 0
Вычисления	FP32, Google Colab, Tesla T4
Среда	PyTorch 2.11.0+cu130, torchvision 0.26.0+cu130

Seed начальных моделей: 11, 111, 211

Итоговых моделей: 22, 122, 222

Случайных подвыборок: 33, 133, 233

Внутри каждого повтора у 3х итоговых моделей одинаковые начальные веса. Между повторами заново вычисляются EL2N и случайная подвыборка. Всего выполнено 12 обучений: 3 начальных и 9 итоговых.

Число шагов и расписание learning rate одинаковы для всех итоговых моделей. На половине данных модель проходит больше эпох, но делает те же 8 000 обновлений весов.

3. Результаты

Точность на тесте, %:

Вариант	Повтор 1	Повтор 2	Повтор 3	Среднее ± SD
Full, 50 000 изображений	88,19	88,22	88,67	88,36 ± 0,27
Random, 25 000 изображений	86,34	86,81	86,35	86,50 ± 0,27
EL2N, 25 000 изображений	87,53	86,54	87,29	87,12 ± 0,52

SD - выборочное стандартное отклонение по 3 повторам, рассчитанное с ddof=1

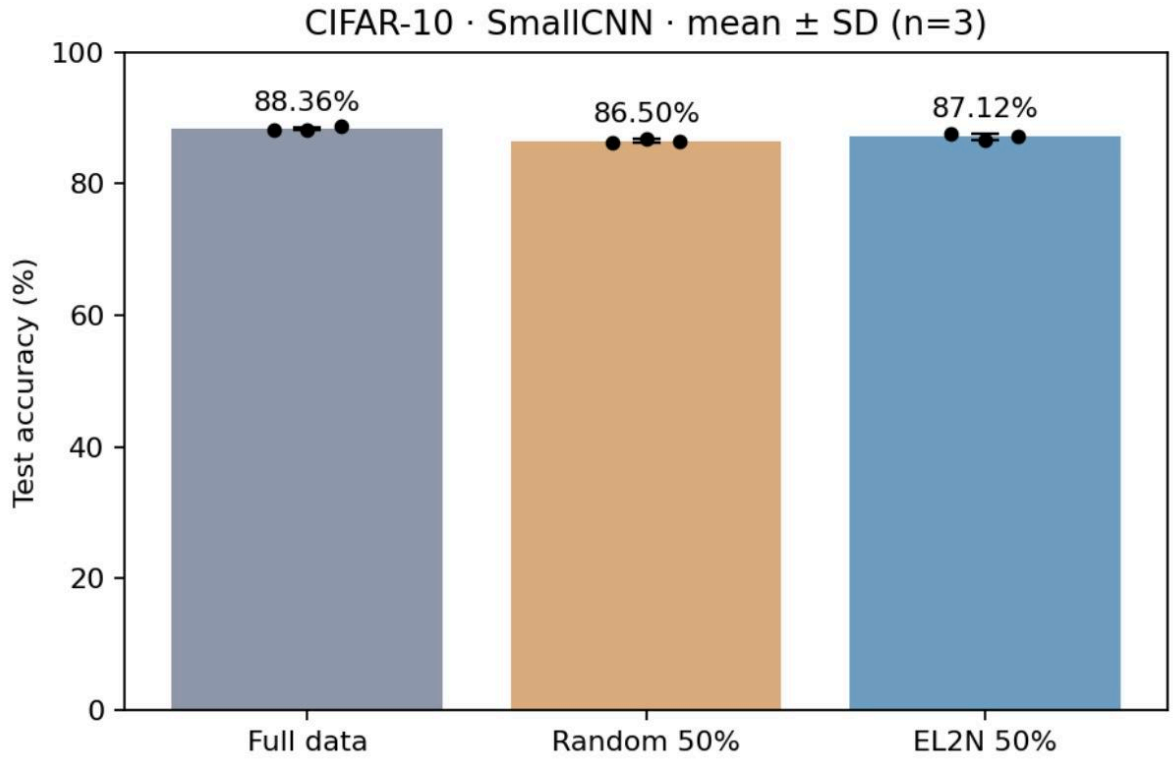


Рис 1. Точность CNN на тестовой выборке CIFAR-10. Столбцы - средние значения по 3 независимым повторам. Отрезки ± одно выборочное стандартное отклонение. Точки - отдельные результаты.

В среднем EL2N превосходит случайный отбор на 0,62 процентного пункта, но уступает обучению на всех данных на 1,24 п.п. Случайный отбор уступает полному набору на 1,86 п.п.

Разности EL2N - Random по повторам составляют +1,19; -0,27; +0,94 п.п. Преимущество наблюдается в 2х повторах из 3х. По средним значениям порядок вариантов: Full > EL2N > Random. Во 2м повторе EL2N уступает Random, поэтому делать вывод о гарантированном преимуществе нельзя.

Среднее время итогового обучения составляет 6,74 минуты для Full, 6,88 для Random и 6,83 для EL2N. Начальное обучение и вычисление EL2N дополнительно занимают в среднем 1,84 минуты. Эти измерения не включают скачивание данных, тестирование и запись контрольных точек. Ускорение обучения в данном протоколе не продемонстрировано.

4. Сопоставление со статьей и ограничения

В статье на CIFAR-10 отбор по EL2N позволяет удалить половину данных без потери точности относительно полного набора в условиях авторов. В нашем эксперименте направление сравнения EL2N с Random совпало по средним значениям, но сохранение точности полного набора не воспроизведено.

Основные отличия от статьи:

1) Небольшая CNN вместо ResNet18
2) 8 000 шагов вместо 78 000 для итогового обучения
3) Cosine-расписание вместо ступенчатого снижения learning rate
4) Одна модель для вычисления EL2N в каждом повторе вместо усреднения оценок по 10 независимым обучениям
5) Три повтора для итоговой точности вместо 4х.

Эти различия могут влиять на точность и устойчивость отбора, и выполненные эксперименты не позволяют установить вклад каждого фактора. Усреднение итоговой точности по 3м повторам не заменяет ансамблевое усреднение EL2N.

GraNd, Forget Score, другие датасеты и влияние момента отбора не проверялись. Полное ранжирование методов статьи не воспроизведено. Трех повторов недостаточно для уверенного утверждения о статистической значимости наблюдаемого преимущества.

5. Вывод

В проведенном эксперименте отбор по EL2N позволил сохранить больше точности при сокращении обучающей выборки вдвое, чем случайный отбор: среднее преимущество составило 0,62 п.п.

Однако оно наблюдалось не во всех повторах, а точность обучения на полном датасете не была достигнута. Полученные результаты частично поддерживают полезность подхода в выбранных условиях.

Источник и материалы

Paul M., Ganguli S., Dziugaite G. K. *Deep Learning on a Data Diet: Finding Important Examples Early in Training*. NeurIPS 2021, версия arXiv:2107.07075v2, 2023.

Код и выводы представлены в data_diet_colab.ipynb. Настройки, версии среды, численные результаты, оценки EL2N, индексы подвыборок и история обучения сохранены в папке results/.